

Estado del Arte en Ingeniería de Datos: Arquitecturas, Herramientas y Tendencias para la Modernización Tecnológica

Nombre: Jean Carlos Cuenca Alvarado

Fecha: 02/05/2026

I. Resumen

El presente documento expone el estado del arte en el campo de Ingeniería de Datos. El objetivo principal es identificar las arquitecturas, herramientas y tendencias actuales que dominan la industria. Se analizan conceptos clave como la evolución de los procesos ETL (Extract, Transform, Load) hacia ELT, y la transición de almacenes de datos tradicionales hacia arquitecturas como Data Lakes y Data Lakehouses basados en la nube, asimismo, se revisaran los trabajos relacionados en el ecosistema tecnológico (Modern Data Stack), estableciendo una base de conocimiento sólida para futuros proyectos de integración y centralización de datos dentro de la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD).

Abstract- This document presents the state of the art in the field of Data Engineering. The primary objective is to identify the current architectures, tools, and trends dominating the industry. Key concepts are analyzed, such as the evolution of ETL processes toward ELT, and the transition from traditional data warehouses to cloud-based architectures like Data Lakes and Data Lakehouses. Additionally, related works within the technological ecosystem (Modern Data Stack) are reviewed, establishing a solid knowledge base for future data integration and centralization projects within the General Directorate of Information Technologies and Digital Transformation (DGTITD).

II. Introducción

En la actualidad, el volumen y la velocidad con la que se genera la información han convertido a los

datos en el activo más valioso para cualquier organización. Sin embargo, extraer valor real de bases de datos aisladas, archivos, plantas y APIs requiere de una infraestructura robusta. Es aquí donde la Ingeniería de Datos se posiciona como la disciplina esencial encargada de diseñar, construir y mantener los flujos de información (pipelines) que hacen posible el análisis avanzado y la toma de decisiones ya que según Gartner[1] "El panorama de los datos está viviendo una transformación acelerada; para 2025, el 75% de la información empresarial será procesada fuera de los centros tradicionales, migrando hacia el borde y la nube. Esta descentralización, sumada a que el 90% de las organizaciones adoptarán estrategias de nube híbrida, posiciona a la infraestructura de datos no solo como una herramienta tecnológica, sino como el eje central de la competitividad empresarial."

La modernización de la infraestructura de datos no es solo una tendencia, sino una necesidad operativa. Adoptar prácticas modernas de integración y agilizar los tiempos de respuesta dentro del DGTITD permitiría reducir la redundancia y mejorar la calidad de la información.

Antes de cualquier solución técnica, es importante comprender el panorama actual de la industria, por lo tanto, este estado del arte tiene como propósito responder a las siguientes interrogantes: ¿Qué arquitecturas se están utilizando en la actualidad para la centralización de datos? ¿Cuáles son las herramientas y plataformas que conforman el stack tecnológico predominante? y ¿Hacia dónde se dirigen las tendencias en el desarrollo de flujos de datos automatizados?

III. Marco Conceptual

Para comprender la evolución el estado actual de las arquitecturas de datos, es necesario definir los conceptos fundamentales de esta área.

A. Ingeniería de Datos

La ingeniería de Datos se define como la práctica de diseñar y construir sistemas para recolectar, almacenar y analizar datos a escala [2]. A diferencia de la Ciencia de Datos, que se enfoca en la creación de modelos predictivos y análisis estadístico, la ingeniería proporciona la infraestructura subyacente y las tuberías (pipelines) que garantizan que los datos sean precisos, accesibles y seguros.

B. Procesos de Integración: ETL vs ELT

Tradicionalmente, la integración de datos se ha realizado mediante procesos ETL, donde los datos se transforman en un servidor intermedio antes de ser cargados [3]. Sin embargo, gracias al poder de cómputo escalable de la nube, el estándar actual es el modelo ELT. En este enfoque los datos crudos se extraen y cargan directamente en el sistema de destino, realizando las transformaciones dentro de la misma base de datos, lo que reduce drásticamente los cuellos de botella [4].

C. Arquitecturas de Almacenamiento

La calidad de los datos decide que tanto puede analizar una empresa

Data Warehouse: Repositorio centralizado diseñado para almacenar datos altamente estructurados y optimizados para consultas rápidas de inteligencia de negocios

Data Lake: Sistema que permite almacenar grandes volúmenes de datos en su formato nativo a un bajo costo [5].

Data Lakehouse: Arquitectura moderna emergente que combina la flexibilidad y estabilidad de una Data Lake con las capacidades de gestión de datos y transacciones ACID de un Data Warehouse

D. ¿Cómo traemos los datos?: Batch vs Streaming

La transferencia de datos se realiza principalmente bajo dos alternativas: procesamiento por lotes Batch (por lotes), donde los datos se mueven en intervalos programados (ej. Cada 24 horas) y procesamiento

Streaming que permite traer los datos y analizarlos en tiempo real [7].

IV. Trabajos Relacionados

La modernización de la infraestructura de datos es un

Desafío global, tanto en la industria privada como en el sector de la educación superior. Diversos estudios han evidenciado como las instituciones académicas están migrando de sistemas monolíticos hacia ecosistema de datos centralizados para mejorar la toma de decisiones.

Por ejemplo, investigaciones recientes detallan la implementación de arquitecturas basadas en Data Lakes en entornos universitarios, permitiendo la consolidación de datos que vienen de sistemas de gestión de aprendizaje LMS, sistemas de información estudiantil SIS y plataformas financieras.[8] Estos trabajos demuestran que centralizar la información reduce la redundancia y facilita la aplicación de analítica predictiva, como la identificación temprana de estudiantes en riesgo de deserción [9].

Desde la perspectiva de la ciberseguridad, la ingeniería de datos también enfrenta desafíos críticos en el manejo seguro de la información que circula por las redes. Investigaciones realizadas en la Universidad Técnica del Norte (UTN) en Ecuador han señalado que las redes WiFi institucionales representan uno de los puntos de mayor vulnerabilidad en el flujo de datos, ya que la información transmitida de forma inalámbrica puede ser interceptada si no se aplican protocolos de cifrado y autenticación adecuados [14]. Esto cobra especial relevancia en entornos universitarios donde los pipelines de datos recogen información sensible a través de conexiones inalámbricas, haciendo necesario que la ingeniería de datos y la ciberseguridad trabajen de manera conjunta para garantizar la integridad, confidencialidad y disponibilidad de los datos desde su origen hasta su destino final.

En el ámbito industrial, reportes técnicos de empresas tecnológicas subrayan la adopción masiva de Modern Data Stack basados en la nube. Casos de estudio resaltan que la transacción de procesos ETL tradicionales a modelos ELT apoyados en plataformas como cloud data warehouses ha

disminuido los tiempos de desarrollo de pipelines de datos en más de un 40%, garantizando una mayor escalabilidad ante el crecimiento exponencial de la información [10].

V. Herramientas y Tecnologías

Hoy en día, las empresas ya no construyen sus sistemas de datos desde cero usando servidores físicos. En su lugar, utilizan un conjunto de herramientas en la nube que trabajan juntas, conocido en la industria como el Modern Data Stack (MDS) o “Pila de Datos Moderna” [11]/

Para entender cómo funcionan estas herramientas, podemos imaginar la ingeniería de datos como una fábrica automatizada, dividida en las siguientes etapas:

A. El transporte

Son los programas encargados de conectarse a las distintas fuentes un ejemplo podría ser el sistema de notas de la universidad o la base de datos de recursos humanos dentro de una empresa y con estos de cierta manera se “copian” los datos hacia un lugar central, otras herramientas más populares actualmente son Fivetran y Airbyte. Su ventaja es que ya tienen conectores listos para usar, lo que ahorra a los ingenieros tener que escribir código desde cero para cada fuente de datos.

B. Almacenamiento en la Nube

Una vez los datos son extraídos, necesitan un lugar seguro y con mucha capacidad para guardarse, en lugar de usar computadoras locales, la tendencia es usar bases de datos en la nube, actualmente los que lideran dicho mercado en ese aspecto son Snowflake, Google BigQuery y Amazon Redshift. Estas plataformas son tan potentes que pueden procesar millones de filas en segundos sin que la institución tenga que preocuparse por el mantenimiento de los servidores físicos [12].

C. Herramientas de Transformación

Los datos que llegan a la bodega suelen estar desordenados. Aquí entra DBT el Data Build Tool, que es actualmente la herramienta más famosa para

transformar datos. Básicamente, permite a los ingenieros usar lenguaje SQL básico para limpiar, ordenar y unir los datos directamente dentro de la bodega en la nube, así de esta manera se los deja listos para que se puedan hacer reportes o gráficos

D. Orquestación

Si tienes muchos pipelines de datos moviendo información, necesitas un sistema que coordine todo. Apache AirFlow es la herramienta estándar para esto. Funciona como un calendario que te dice Primero extrae los datos a las 2:00 am, cuando termines límpialos a las 2:30 am y si algo falla envíame un correo alertándome.

VI. Tendencias y Futuro

La ingeniería de datos cambia muy rápido. Al observar hacia dónde va la industria en los próximos uno a tres años, destacan dos grandes tendencias que busca solucionar los problemas de lentitud y cuellos de botella [13].

A. Data Mesh

Hasta hace poco, la idea era que un solo equipo de Ingenieros de Datos manejara toda la información de una institución. El problema es que ese equipo se satura de trabajo. La nueva tendencia, llamada Data Mesh, propone descentralizar el trabajo. Esto significa que cada departamento por ejemplo el área financiera o el área académica sea responsable de limpiar y organizar sus propios datos, tratándolos como si fueran un producto que le entregan al resto de la universidad.

B. Inteligencia Artificial en la Ingeniería de Datos

La llegada de la Inteligencia Artificial Generativa (como los modelos de lenguaje) está cambiando como trabajan los ingenieros. En el futuro cercano, estas herramientas utilizarán IA para ayudar a escribir automáticamente el código necesario para limpiar los datos scripts en SQL o Python, que detectaran anomalías o errores en la información de manera automática y generara la documentación técnica que a los humanos nos toma mucho tiempo escribir.

C. Procesamiento en Tiempo Real

Históricamente, los datos se actualizaban una vez al día durante la madrugada. La tendencia actual es moverse hacia el procesamiento en Streaming usando tecnologías como Apache Kafka. Esto permite que, en el momento en que un estudiante se matricula o realiza un pago, esa información se refleje en los paneles de control de universidad en cuestión de segundos, no el día siguiente.

VII. Conclusiones

La investigación realizada en este estado del arte permite extraer conclusiones claras sobre cómo ha evolucionado la gestión de la información y cómo debe abordarse en la actualidad:

1. **La Nube como estándar:** Las instituciones ya no necesitan comprar y mantener servidores costosos físicos. La tendencia indiscutible es migrar hacia la nube utilizando modelos ELT (Extraer, Cargar y Transformar), lo que permite procesar grandes cantidades de datos de forma mucho más rápida y económica.
2. **El dominio del Modern Data Stack:** Existe un consenso en la industria sobre las mejores herramientas a utilizar. Separar el trabajo usando herramientas específicas para ingesta (como Airbyte o Fivetran), almacenamiento (Snowflake o BigQuery), transformación (dbt) y orquestación (Airflow) es la mejor manera de construir sistemas que no fallen y sean fáciles de mantener.
3. **Preparación para el reto en la DGTITD:** Aunque aún no se ha definido el problema técnico específico a resolver durante esta práctica, comprender este ecosistema tecnológico es el primer paso crítico. Conocer qué se está haciendo ahora, con qué herramientas y hacia dónde va el campo (como la descentralización con Data Mesh), me otorga una base sólida. Esto me permitirá evaluar la infraestructura de datos actual de la universidad y proponer soluciones que sean modernas, eficientes y alineadas con los estándares globales de la industria.

VIII. Referencias

- [1], [2], [12] E. L. Jimbo-Landi y J. P. Cuenca-Tapia, “Modernización de la infraestructura tecnológica de datos de la Cooperativa Jardín Azuayo mediante hiperconvergencia,” *Revista Científica FIPCAEC*, ISSN: 2588-090X, vol. 5, no. 16, pp. 79–101, 2020. Universidad Católica de Cuenca, Ecuador. [En línea]. Disponible: <https://doi.org/10.23857/fipcaec.v5i14.161>
- [3], [5], [6] J. C. Agudelo-Patiño, “Data Lakes: Aplicaciones, Herramientas y Arquitecturas,” Monografía de grado, Facultad de Ingenierías, *Universidad Tecnológica de Pereira*, Pereira, Colombia, 2020. [En línea]. Disponible: <https://repositorio.utp.edu.co/handle/11059/11874>
- [4], [7], [10] A. Mbata, Y. Sripada y M. Zhong, “A Survey of Pipeline Tools for Data Engineering,” *arXiv preprint*, arXiv:2406.08335, University of Aberdeen, Reino Unido, jun. 2024. [En línea]. Disponible: <https://arxiv.org/abs/2406.08335>
- [8], [9], [11] F. A. Soto-Hidalgo, A. G. López-Herrera y J. M. Fernández-Luna, “Utilización de Big Data en la educación superior: Una revisión sistemática de la literatura entre 2019-2023,” *Dialnet – Revista Iberoamericana de Educación Superior*, 2024. [En línea]. Disponible: <https://dialnet.unirioja.es/servlet/articulo?codigo=10003333>
- [13] M. Armbrust et al., “Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics,” en *Proc. 11th Annual Conference on Innovative Data Systems Research (CIDR 2021)*, Chaminade, CA, USA, ene. 2021. [En línea]. Disponible: http://cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf
- [14] D. Arévalo y P. Quiñonez, “Análisis de Vulnerabilidades en Redes WiFi Institucionales y su Impacto en la Seguridad de los Flujos de Datos,” *Revista Ingeniería, Ciencia y Tecnología — UTN*, Universidad Técnica del Norte, Ibarra, Ecuador, vol. 5, no. 1, pp. 34–47, 2023.

